

Fundamentos Teoricos de Feature Engineering en Senales Fisiologicas

Documento Standalone para TFG

Proyecto FatigueSet

21 de abril de 2026

Índice general

1. Introduccion y alcance	3
2. Preparacion de datos y control de calidad	4
2.1. Modelado de valores faltantes y valores no finitos	4
2.2. Escalado estandar y comparabilidad entre modalidades	4
2.3. Riesgo de data leakage en preprocesamiento	5
3. PCA: reduccion dimensional lineal	6
3.1. Formulacion algebraica	6
3.2. Criterio del 95 % y lectura del notebook	6
3.3. Cargas, contribuciones y lectura fisiologica	7
3.4. Supuestos y limitaciones de PCA	7
4. t-SNE: visualizacion no lineal de estructura local	8
4.1. Idea central del metodo	8
4.2. Perplexity y estabilidad	8
4.3. Errores de interpretacion frecuentes	9
5. Clustering con K-Means y validacion por silhouette	10
5.1. Funcion objetivo y algoritmo de Lloyd	10
5.2. Seleccion de K con silhouette	10
5.3. Interpretacion fisiologica prudente	11
6. Random Forest e importancia de variables	12
6.1. Fundamentos del modelo	12
6.2. Importancia por disminucion de impureza	12
6.3. Rendimiento y leakage	13
6.4. Limitaciones de importancia en Random Forest	13
7. Correlacion lineal y estructura bivariada	14
7.1. Coeficiente de Pearson	14
7.2. Lectura correcta del heatmap	14

8. Reproducibilidad, validez y buenas practicas	15
8.1. Semillas y estabilidad computacional	15
8.2. Validacion estadistica recomendada	15
8.3. Tamano muestral y complejidad del modelo	15
9. Sintesis teorica por bloque del notebook	16
9.1. Resumen integrador	16
10.Conclusiones y extensiones futuras	17

Capítulo 1

Introduccion y alcance

El notebook *Feature_Engineering_Fisiologico.ipynb* implementa un flujo completo de analisis sobre un conjunto agregado de variables fisiologicas, incluyendo limpieza, normalizacion, reduccion dimensional, visualizacion no lineal, clustering, importancia de variables y analisis de correlacion. Este documento desarrolla en profundidad el marco teorico de cada bloque metodologico, con formalismo matematico, supuestos, limitaciones y criterios de interpretacion.

Desde el punto de vista de modelado, el problema se puede resumir como sigue: dado un conjunto de muestras $\{\mathbf{x}_i\}_{i=1}^n$, con $\mathbf{x}_i \in \mathbb{R}^p$ y etiquetas o variables clinicas asociadas, se busca extraer representaciones utiles para (i) describir la estructura latente de los datos, (ii) identificar variables con relevancia predictiva y (iii) construir una narrativa fisiologica coherente sobre fatiga.

En el notebook analizado se trabaja con $n = 108$ observaciones y $p = 19$ variables agregadas. Aunque el volumen no es grande, el enfoque es representativo de un escenario real de investigacion aplicada en salud digital: pocos sujetos, medicion multimodal y alta necesidad de interpretabilidad.

Capítulo 2

Preparacion de datos y control de calidad

2.1. Modelado de valores faltantes y valores no finitos

Sea $X \in \mathbb{R}^{n \times p}$ la matriz de datos numericos. Antes de aplicar tecnicas como PCA o K-Means, es necesario garantizar que no existan entradas no finitas.

- Valores infinitos $(+\infty, -\infty)$ pueden surgir por divisiones entre cero o errores de adquisicion.
- Valores faltantes (NaN) pueden aparecer por perdida temporal de senal, artefactos o fallos del sensor.

En terminos formales, se define una funcion de saneamiento por componente:

$$\tilde{x}_{ij} = \begin{cases} \mu_j, & \text{si } x_{ij} \in \{\text{NaN}, +\infty, -\infty\}, \\ x_{ij}, & \text{en otro caso,} \end{cases}$$

donde μ_j es la media muestral de la variable j calculada sobre valores observados.

La imputacion por media es una estrategia simple y estable para pipelines exploratorios; sin embargo, reduce la varianza efectiva de la variable imputada y puede sesgar relaciones multivariadas si el mecanismo de faltantes no es MCAR (Missing Completely At Random) [7].

2.2. Escalado estandar y comparabilidad entre modalidades

Las variables fisiologicas suelen estar en escalas heterogeneas: por ejemplo, frecuencia cardiaca en latidos por minuto, EDA en microsiemens y potencias EEG en unidades relativas. Si no se corrige esta heterogeneidad, metodos basados en distancias euclideas quedan dominados por variables de mayor magnitud numerica.

El notebook aplica estandarizacion tipo z-score:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j},$$

donde μ_j y σ_j representan media y desviacion tipica muestral de la variable j .

Propiedades clave de esta transformacion:

- Centra cada variable en cero y la lleva a varianza aproximada unitaria.
- Preserva orden relativo y relaciones lineales, pero no acota valores en un intervalo fijo.
- Facilita la interpretacion de cargas en PCA y mejora estabilidad numerica en optimizacion.

Alternativas comunes incluyen Min-Max scaling y Robust scaling. Robust scaling puede ser preferible cuando existen colas pesadas o outliers significativos [3].

2.3. Riesgo de data leakage en preprocesamiento

Una fuente clasica de sesgo metodologico es ajustar transformaciones con todo el dataset antes de separar entrenamiento y prueba. Si μ_j y σ_j se estiman usando tambien muestras de test, se introduce informacion futura en el entrenamiento.

En notacion de particion:

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}}, \quad \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset.$$

La practica correcta exige:

$$\hat{\mu}_j, \hat{\sigma}_j \leftarrow \mathcal{D}_{\text{train}},$$

y luego transformar ambas particiones con esos parametros fijos.

Este punto no invalida un analisis exploratorio, pero si limita inferencias de generalizacion [6].

Capítulo 3

PCA: reduccion dimensional lineal

3.1. Formulacion algebraica

PCA busca una base ortonormal $\{\mathbf{w}_k\}_{k=1}^p$ que maximize varianza proyectada. Con datos estandarizados Z , la matriz de covarianza es:

$$\Sigma = \frac{1}{n-1} Z^\top Z.$$

Se resuelve el problema espectral:

$$\Sigma \mathbf{w}_k = \lambda_k \mathbf{w}_k,$$

con autovalores ordenados $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

La k -esima componente principal para muestra i se obtiene como:

$$t_{ik} = \mathbf{z}_i^\top \mathbf{w}_k.$$

La fraccion de varianza explicada por componente k es:

$$\text{EVR}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j},$$

y la varianza acumulada de las primeras m componentes:

$$\text{CV}(m) = \sum_{k=1}^m \text{EVR}_k.$$

3.2. Criterio del 95 % y lectura del notebook

El notebook estima el minimo m tal que $\text{CV}(m) \geq 0,95$. En ejecucion reciente, el resultado fue $m = 12$, con aproximadamente 28.8 % de varianza en PC1 y 44.8 % en PC1+PC2.

Interpretacion:

- El sistema fisiologico no se resume en dos ejes lineales sin perdida relevante.

- Existe redundancia, pero también complejidad multimodal: se requieren varias direcciones para capturar dinámica total.
- La proyección 2D es útil para exploración visual, no para representar exhaustivamente la estructura original.

3.3. Cargas, contribuciones y lectura fisiológica

Las cargas de PCA (elementos de $\mathbf{w}_k$) cuantifican contribución de cada variable original a cada componente. Una lectura robusta exige:

1. Revisar magnitudes absolutas altas en cada componente.
2. Contrastar signos para identificar oposición entre modalidades.
3. Verificar estabilidad de cargas bajo remuestreo.

Una limitación importante es la ambigüedad de signo: si $\mathbf{w}_k$ es solución, también lo es $-\mathbf{w}_k$. Por ello, la interpretación debe basarse en patrón relativo, no en signo absoluto aislado.

3.4. Supuestos y limitaciones de PCA

- Relación lineal: patrones fuertemente no lineales pueden no capturarse bien.
- Sensibilidad a outliers: observaciones extremas alteran covarianza.
- Enfoque no supervisado: PCA no optimiza discriminación de una etiqueta concreta.
- Interpretabilidad parcial: componentes son combinaciones abstractas, no variables fisiológicas directas.

Fundamentos clásicos de PCA se remontan a Pearson y Hotelling [11, 4, 5].

Capítulo 4

t-SNE: visualizacion no lineal de estructura local

4.1. Idea central del metodo

El algoritmo t-SNE (t-Distributed Stochastic Neighbor Embedding) construye una representacion en baja dimension preservando vecindades locales [12]. Primero transforma distancias en altas dimensiones en probabilidades de vecindad:

$$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2/2\sigma_i^2)}.$$

Luego simetriza:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}.$$

En el espacio embebido $Y = \{\mathbf{y}_i\}$ usa una distribucion t de Student con un grado de libertad:

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}}.$$

La optimizacion minimiza divergencia de Kullback-Leibler:

$$\text{KL}(P\|Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

4.2. Perplexity y estabilidad

La perplexity controla el tamano efectivo de vecindad local y se relaciona con la entropia de $p_{j|i}$:

$$\text{Perp}(P_i) = 2^{H(P_i)}.$$

En muestras pequenas, valores moderados (por ejemplo 5–30) suelen evitar sobrefragmentacion visual.

Aunque en el notebook se fija semilla para reproducibilidad, t-SNE sigue siendo sensible a hiperparametros e inicializacion. Por tanto, se recomienda comparar multiples corridas y no inferir estructura clinica solo por una configuracion.

4.3. Errores de interpretacion frecuentes

- Distancias globales: t-SNE preserva estructura local, no metrica global.
- Tamano aparente de clusters: puede ser artefacto visual del embedding.
- Separacion visual no implica separacion estadistica robusta.

Para soporte inferencial, la visualizacion debe combinarse con metricas cuantitativas y validacion externa.

Capítulo 5

Clustering con K-Means y validacion por silhouette

5.1. Funcion objetivo y algoritmo de Lloyd

K-Means busca particionar n observaciones en K grupos minimizando suma de distancias cuadraticas intra-cluster:

$$\min_{\{C_k\}_{k=1}^K} \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2,$$

donde $\boldsymbol{\mu}_k$ es el centroide de cluster k .

El algoritmo de Lloyd alterna:

1. Asignacion: cada punto al centroide mas cercano.
2. Actualizacion: recalculo de centroides como media del cluster.

Con inicializacion k-means++ se mejora convergencia y estabilidad en muchos escenarios [8, 10].

5.2. Seleccion de K con silhouette

Para cada muestra i , se define:

$a(i)$ = distancia media a su propio cluster,

$b(i) = \min_{k \neq c(i)} \text{distancia media al cluster } k$.

El coeficiente silhouette individual es:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1].$$

El indice global es el promedio de $s(i)$.

En el notebook, el mejor valor observado fue $K = 2$ con silhouette aproximado de 0.407. Esto sugiere estructura moderada: hay separacion util, pero no fuertemente definida.

5.3. Interpretacion fisiologica prudente

Encontrar dos clusters no implica automaticamente dos estados clinicos puros. Pueden reflejar combinaciones de intensidad, fase experimental, diferencias inter-sujeto o factores no controlados. Se recomienda perfilar clusters con estadística descriptiva por variable y metadatos de protocolo antes de asignar significado causal.

Capítulo 6

Random Forest e importancia de variables

6.1. Fundamentos del modelo

Random Forest combina multiples arboles entrenados sobre remuestreo bootstrap y submuestreo aleatorio de variables por nodo [1]. Para regresion, la prediccion final es promedio:

$$\hat{f}(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T f_t(\mathbf{x}),$$

donde T es numero de arboles.

Ventajas relevantes:

- Capta no linealidades e interacciones sin especificacion explicita.
- Alta robustez frente a ruido moderado.
- Permite extraer medidas de importancia de variables.

6.2. Importancia por disminucion de impureza

La importancia por MDI (Mean Decrease in Impurity) acumula reducciones de impureza generadas por una variable a traves de todos los arboles. Si una variable participa en divisiones que reducen fuertemente el error cuadratico, su importancia aumenta.

Formalmente, para variable j :

$$\text{Imp}(j) = \frac{1}{T} \sum_{t=1}^T \sum_{v \in \mathcal{V}_{t,j}} \Delta I(v),$$

donde $\mathcal{V}_{t,j}$ son nodos del arbol t que dividen con variable j , y $\Delta I(v)$ la reduccion de impureza en ese nodo.

6.3. Rendimiento y leakage

En una iteracion previa del notebook se observo un R^2 casi perfecto por incluir accidentalmente la variable objetivo entre predictores. Tras corregir ese leakage, el valor se situo alrededor de $R^2 = 0,916$, mas plausible para un ajuste in-sample.

Este caso ilustra un principio central: importancia y desempeno deben interpretarse solo tras verificar que no existe fuga de informacion. Adicionalmente, un buen ajuste sobre entrenamiento no garantiza generalizacion.

6.4. Limitaciones de importancia en Random Forest

- Sesgo potencial hacia variables con mayor variabilidad o cardinalidad.
- Sensibilidad a multicolinealidad: dos variables correlacionadas pueden repartirse importancia.
- No implica causalidad fisiologica.

Por ello, se recomienda complementar con permutation importance y metodos basados en Shapley values en trabajos futuros [2, 9].

Capítulo 7

Correlacion lineal y estructura bivariada

7.1. Coeficiente de Pearson

El coeficiente de correlacion lineal de Pearson entre variables X y Y se define como:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Sus valores estan en $[-1, 1]$ y miden asociacion lineal.

En el notebook se visualiza una submatriz de variables de mayor varianza para mejorar legibilidad del heatmap. Esta eleccion es practica para exploracion, aunque no sustituye pruebas de significacion ni analisis de correlacion parcial.

7.2. Lectura correcta del heatmap

- Correlacion alta no implica relacion causal.
- Relaciones no lineales pueden pasar desapercibidas con Pearson.
- En presencia de variables confusoras, las correlaciones bivariadas pueden inducir interpretaciones erroneas.

Una ruta mas robusta incluye modelos multivariados y analisis estratificado por sujeto, sesion o intensidad.

Capítulo 8

Reproducibilidad, validez y buenas practicas

8.1. Semillas y estabilidad computacional

El flujo fija semillas aleatorias para reproducibilidad. Esta practica mejora trazabilidad, pero no elimina toda variabilidad en metodos como t-SNE, donde pequenas perturbaciones pueden cambiar geometria visual final.

8.2. Validacion estadistica recomendada

Para transicionar de EDA a evidencia predictiva, se recomienda:

1. Separacion entrenamiento-prueba por sujeto para evitar contaminacion temporal.
2. Validacion cruzada estratificada segun estructura experimental.
3. Reporte de intervalos de confianza via bootstrap.
4. Analisis de sensibilidad a hiperparametros.

8.3. Tamano muestral y complejidad del modelo

Con $n = 108$, el margen para modelos complejos es limitado. Un principio util es controlar relacion muestra/parametros efectivos para evitar sobreajuste. La combinacion de reduccion dimensional, regularizacion implicita y validacion rigurosa es preferible a aumentar complejidad sin control.

Capítulo 9

Sintesis teorica por bloque del notebook

9.1. Resumen integrador

Cuadro 9.1: Bloques del notebook y su significado teorico principal

Bloque	Marco teorico	Riesgo principal
Limpieza e imputacion	Calidad de datos, inferencia bajo faltantes	Sesgo por mecanismo de missingness
Estandarizacion	Comparabilidad de escala en metodos metricos	Leakage si se ajusta con test
PCA	Proyeccion lineal de maxima varianza	Perdida de estructura no lineal
t-SNE	Preservacion de vecindad local en embedding	Sobreinterpretacion visual global
K-Means + silhouette	Segmentacion no supervisada y cohesion/separacion	Asuncion de clusters esfericos
Random Forest importance	Relevancia predictiva no lineal	Importancia no causal, co-linealidad
Correlacion	Dependencia lineal bivariada	Confusion y no causalidad

El valor del pipeline no reside en una unica tecnica aislada, sino en la triangulacion entre metodos: PCA resume, t-SNE explora, K-Means segmenta, Random Forest prioriza variables y la correlacion ayuda a interpretar acoplamientos.

Capítulo 10

Conclusiones y extensiones futuras

Este desarrollo teorico muestra que el notebook implementa un pipeline coherente para exploracion avanzada de senales fisiologicas agregadas. Su mayor fortaleza es la combinacion de metodos complementarios con decisiones de preprocesamiento explicitadas.

Para elevar el nivel metodologico a estandar de publicacion, las extensiones prioritarias son:

- Validacion fuera de muestra con diseno por sujeto.
- Comparativas sistematicas (UMAP vs t-SNE, GMM/DBSCAN vs K-Means).
- Importancia robusta (permutation y SHAP).
- Integracion de incertidumbre estadistica en todos los reportes.

En conjunto, el marco teorico aqui presentado sirve como base formal para justificar decisiones del feature engineering y para defender su interpretacion en un TFG de orientacion cientifica.

Bibliografía

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [2] Aaron Fisher, Cynthia Rudin, and Francesca Dominici. All models are wrong, but many are useful: Variable importance for black-box, proprietary, or misspecified prediction models. *Journal of Machine Learning Research*, 20(177):1–81, 2019.
- [3] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.
- [4] Harold Hotelling. Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6):417–441, 1933.
- [5] Ian T. Jolliffe. *Principal Component Analysis*. Springer, 2 edition, 2002.
- [6] Sayash Kapoor and Arvind Narayanan. Leakage and the reproducibility crisis in ml-based science. *Patterns*, 4(9):100804, 2023.
- [7] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley, 3 edition, 2019.
- [8] Stuart Lloyd. Least squares quantization in pcm. *IEEE Transactions on Information Theory*, 28(2):129–137, 1982.
- [9] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 2017.
- [10] James MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297, 1967.
- [11] Karl Pearson. On lines and planes of closest fit to systems of points in space. *Philosophical Magazine*, 2(11):559–572, 1901.
- [12] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9:2579–2605, 2008.